

第2章

関連研究

2.1 序言

本章では，COLLAGREE の概要と議論支援及び本研究で支援することを目標とするファシリテーターについて説明し，既存の議論支援研究や話題遷移を扱う関連研究についても説明するとともに本研究との違いを述べる．更に本研究の重要な要素である重み付けと分散表現についても詳しく述べる．

本章の構成を以下に示す．まず，2.2 節では，COLLAGREE の概要について簡単に述べる．2.3 節では，既存の議論支援に関する研究について述べる．2.4 節では話題に関する本研究の見方や既存の話題に関する研究について述べる．次に，2.5 節では本研究の重要な要素である重み付けについて述べる．2.6 節では本研究のもう 1 つの重要な要素である分散表現及び分散表現を使用した話題関連研究について述べる．最後に，2.7 節で本章のまとめを示す．

2.2 COLLAGREE

2.2.1 COLLAGREE 開発の背景

本研究による議論とは加藤ら [?] の定義した”ある特定の問題を解決することを目的とし、2 者以上の間で言語的・非言語的媒介を通して意思疎通をすること”である。近年、Web 上での大規模な意見集約や議論を実現する研究に注目が集まっている。Web 上で話をする場として Twitter や Facebook などの SNS、ブログ、および掲示板といったプラットフォームがあるが、大規模な人数での意見集約を行うことや合意形成を行うことは困難である。なぜなら、議論の管理や整理を行う人物がおらず、「炎上」と呼ばれる議論の無秩序の状態がよく観測されているためである。そこで、伊藤ら [?] は、Web 上での大規模な意見集約を目的とした大規模意見集約システム COLLAGREE を開発した。本研究では、開発した COLLAGREE を用いて、提案した手法に関する調査、分析を行う。図 2.1 に COLLAGREE のトップ画面を示す。

2.2.2 COLLAGREE の概要

COLLAGREE は掲示板のような議論プラットフォームをベースにしており、各ユーザーが自由なタイミングで意見を投稿、返信できる。しかし、2.2.1 節で述べたように多様な価値観を持つ大規模な人数での、自由な議論では「炎上」が発生しやすい。従って、COLLAGREE では、議論のマネジメント役として人間のファシリテーターが導入されている。COLLAGREE のような議論掲示板は基本的には 1 つの議論テーマに対して関連するテーマを扱った複数のスレッドから構成される。スレッドとはある特定の話題・論点に関する 1 つのまとまりを指す。例えば、



図 2.1: COLLAGREE のトップ画面

図 2.2 のようにスレッドを立てたユーザーの発言が親意見となり，他のユーザーが子意見として親意見に返信し，子意見に対して孫意見が存在する場合もある。

しかし，スレッドや返信は必ずしも正しく使われるとは限らず，単なるチャットと同様に扱われてしまいスレッドが乱立してしまうこともある．図 2.3 に COLLAGREE での実際の議論画面を示す．

図 2.3 の上部の投稿フォームより，参加者は意見を自由に投稿することができる．投稿された意見は図 2.3 の下部に表示され，参加者は各意見に対して返信や賛同を行うことができる．返信を繰り返すことでスレッドが構成され，図 2.3 では 3 層のスレッドが構成されている．COLLAGREE 上での議論を支援する先行研究として，Ito ら [?] は COLLAGREE 上インセンティブとして参加者の活動の活発化や，重要投稿の把握の支援を目的に議論ポイントと呼ばれるシステムを導入した．システムでは参加者の投稿や投稿に対する返信や賛同に沿ってポイントを参加者に付与する．また，高橋ら [?] は質の高い投稿を促すために，議論ポイントを発展




図 2.2: COLLAGREE のスレッドの例

図 2.3: COLLAGREE の議論画面

COLLAGREE
運営主体
操作方法
ようこそ、せんだいさん
管理者
ログアウト

議論
ランキング
議論ツリー

Post / 投稿

ファシリテーション
投稿

あなたの意見のタイトルを入力してください。(20字以下)

ファシリテーションしましょう

この意見を合意案とする
スタンプ
ファシリテーションフレーズ

ようしくお願ひします!!
うーん
GOOO!!
決定!!
お願ひします!!
ありがとう
すみません...
うーん...

ファシリテーターとして投稿

News from the facilitator / ファシリテータからのお知らせ

発散フェイズ
収束フェイズ
合意フェイズ

合意フェイズって？
合意フェイズは最終的な合意案を作成するフェイズです。収束フェイズまでに出た案を吟味し、最終的な案の質を上げていきましょう！

議論ツリーについて
一番上のタブの「議論ツリー」から議論ツリーを見ることができます。
収束フェイズで議論内容を確認したいときや自分の意見をまとめたいときに使ってみてください

コメント更新

【並び替え】
● 新着
○ ポイント
【絞り込み】
☐ 教育
☐ 問題点
☐ マインド
☐ マインド
検索

15.0 points

ネットでの事件
実際にみなさんが遭遇したネットでの事件を書き込んでみましょう？
そこから私たちに本当に必要なネットリテラシーが見えてくるのでは？

例えば
・変なサイトにアクセスして迷惑メールが増えた
・詐欺にあった
・ネットショッピングでのミス
などなど...

SSA · 12/04 00:02
いいね 1
いいね 0
いいね 0件
投稿No.221
返信する

15.0 points

私はフリーソフトをよくダウンロードするのですが、そのときに悪質なアドウェアが入り込んでしまっただけで除去に苦労することがありました。
インストールするときには何か変なオプションがないか確認を心がけることが必要だと実感しましたね。

たけし · 12/04 05:39
いいね 1
いいね 0件
投稿No.225
返信する

0.0 points

どのようなソフトが安全かなどの認識は大切ですね。
例えば
作成者がはっきりしているなど

SSA · 12/04 13:58
いいね 1
いいね 0件
投稿No.232
返信する

Theme / テーマ

これから必要なネットリテラシー教育とは？[B]

近年、ネット上のコミュニケーションツールは日々進化しており、それに伴って必要とされるネットリテラシーも変化しています。ここでは、近年求められるネットリテラシーについて、事例やニュースをもとに考え、これからの若い世代にどのようなネットリテラシー教育を施すべきなのかを考察しましょう。

53
124

総合ポイントランキング

順位	ユーザー	ポイント
1	ファーマ	863
2	まさっぺ	646
3	M_wakkey	570
4	SSA	538
5	ふははははは	448

Keywords / キーワード

スコア	キーワード
0.158903	ネット上
0.10755	現実世界
0.101273	ネットリテラシー教育
0.0926403	危険性 可能性 スマートフォン

Tags / 論点タグ

+

教育
問題点
マインド
マインド

5

させて投稿された意見の質を評価する手法を提案した。投稿された意見中の名詞と以前に出現したキーワードとの一致度を計算し、一致していれば議論を収束させるものとして、一致していなければ議論を発散させるものとしてポイントを与える。他に議論の可視化支援として、仙石ら [?] は議論内容把握支援、合意形成支援、およびファシリテーション支援を目的として議論ツリーの実装を行った。ツリー図を COLLAGREE に応用したものを仙石らが呼んだもので、ツリー図とはファシリテーターが参加者に議論のポイントと各意見の関係を一致させるために、参加者の意見を文字や図形を用いて分かりやすく描く図の1つである。図 2.4 に議論ツリーの例を示す。議論ツリーは投稿をノードとし、エッジは基本的に投稿間

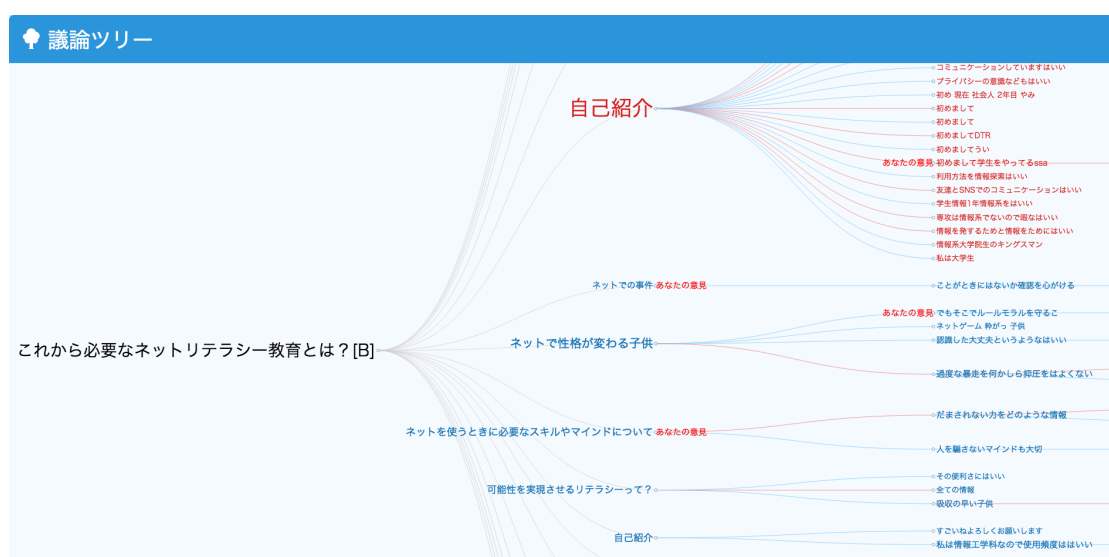


図 2.4: 議論ツリー

の返信関係を基に自動的に作られる。そして、より正確な議論ツリーを作成するためにファシリテーターが手動で議論ツリー編集するというハイブリッド方式が導入されている。

2.2.3 ファシリテーター

COLLAGREE ではファシリテーターと呼ばれる人物が議論のマネジメントを行っている。ファシリテーターは”促進者”を意味し、議論そのものには参加せず、あくまで中立的な立場から活動の支援を行うようにし、自分の意見を述べたり自ら意思決定をすることはない。ファシリテーターの基本的な役割として”議論の内容の整理”，”議論の脱線防止”，”意見の促し”等が挙げられる。ファシリテーターが様々な論点に対する発言を促すことによって、議論が発散するため、十分な議論が行われる。そのため、ファシリテーターの存在や手腕が合意形成に強く影響を与えることや Web 上での議論においてファシリテーターが有用であることが伊藤ら [?] や伊美ら [?] によって示されている。

2.3 議論支援

2.2.1 節で述べたように近年大人数による議論には注目が集まっており、COLLAGREE 以外でも議論内容の把握支援を行い、議論の進行を支援するための研究が行われている。小谷ら [?] は好意的発言影響度を取り入れた議論支援システムを開発した。システムは議論中の発言の意図や内容に加えて、発言に対するリアクション (同意, 非同意, 意見) などから議論進行をモニタリングしている。モニタリングの結果を基にして議論の活性化や深化に対して参加者が果たしている役割を”好意的発言影響度”として定量化して表示する。以上を踏まえて、本研究と小谷らの開発した議論支援システムとの関連性と相違点について述べる。両研究とも発言が議論に与える影響を扱っている点で関連している。しかし、小谷らは一般参加者や学習者の議論活性化及び収束に向けた支援を目的としているが、本研

究はファシリテーターに対する支援を目的としている点で異なる。

2.4 話題遷移検出

話題に関連する研究は1960年代に「会話分析」という学問から始まったとされる。会話分析は会話を始めとする相互行為の組織(構造)を明らかにしようとする社会学の研究分野であり、相互行為の分析法を取り扱う。1960年代に Harvey Sacks と Emanuel A. schegloff によって創案された[?]。話題は本来流れの一時点で簡単に区切ることでできるものではない。しかし、会話内容进行分析の上では話題を区切る必要がある。筒井[?]は会話内容进行分析の上で、連鎖組織及び言語形式との関連に基づいて分析を行っている。以下に筒井が立てた話題を区切る基準を1から5に示す。

1. それまで話題となっていた対象や事態とは異なる、新しい対象や事態への言及
2. すでに言及された対象や事態の異なる側面への言及
3. すでに言及された対象や事態の異なる時間における様相への言及
4. すでに言及された対象や事態について、それと同種の対象や事態への言及
5. すでに言及された個別の対象や事態の一般化

本研究では上記の基準を参考に話題変化判定の評価基準を設けている。

話題の遷移に基づいた文章の分割は人間によるテキスト全体の内容の把握の容易化や複数のテキストに対する自動分類や検索の精度向上のために研究されている。以下では話題の遷移に関する関連研究について述べる。

2.4.1 テキストセグメンテーション

テキストセグメンテーションは複数のトピックが混合的に書かれている非構造的である文書をトピックに応じて分割する手法である。

TextTiling

Hearst ら [?] は複数の単語を連結した 2 つのブロックをテキストの初めから末尾まで動かしていきブロック間の類似度を計算する手法 (TextTiling, Hearst 法とも呼ばれる) を提案した。類似度はブロック間で共通して使われる単語数などで計算する。図 2.5 に手法の簡単な流れを示す。

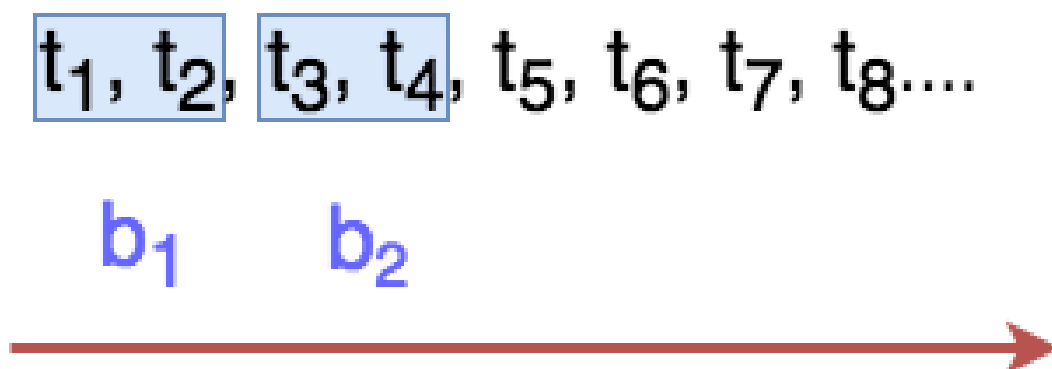


図 2.5: TextTiling の流れ

計算された類似度をグラフにすると図 2.6 のようになる。縦軸はブロック間の類似度、横軸はブロック間の番号を表し、グラフ中の番号は段落番号、垂直線は選出された文の境界位置を表す。グラフは各ブロック間の類似度を繋いだものと、更に平滑化したものの 2 つが描かれている。グラフの谷のような場所は左右のブロック間の類似度が下がる場所を表している。類似度が下がることは使われる単語が変わったこと、すなわちトピックが変わったことを意味しており、谷の付近に境界を設けることで文書をトピックごとに区切ることを可能としている。




図 2.6: TextTiling のグラフ

テキストセグメンテーションを使用した関連研究

別所 [?] は単語の共起頻度行列を特異値分解で次元を削減して作成した単語の概念ベクトルを用いて、連結された新聞記事を元の形になるように分割をする実験を行っている。TextTiling を用いてブロック間の類似度を計算する際にブロック中の単語の中で自立語にのみ概念ベクトルを付与し、左右のブロックの和ベクトル (または重心ベクトル) の余弦測度を求め、類似度 (または結束度) としている。

以上を踏まえて、本研究とテキストセグメンテーションを用いた研究との相違点について述べる。テキストセグメンテーションは基本的にある地点 A で話題に沿って分割をするか考える際に、地点 A より先の情報を使うことができる。すなわち、ある程度の文章が現れてから話題が変わったかどうかの判定をしており、リアルタイムでの動作を想定していない。本研究はリアルタイムでの動作を想定し、ある発言 B が話題の変化を起こすかどうか判定する際に B より先の情報を使うことなく判定している点で異なる。

2.4.2 トピックモデル

トピックモデル [?] は確率モデルの一種にあたり、文章中の「単語が出現する確率」を推定している。単語が出現する確率をうまく推定することができれば、似たような単語が出てくる文章が把握できる。すなわち、トピックモデルとは「文書における単語の出現確率」を推定するモデルといえる。

ユニグラムモデル

以下の図 2.7, 図 2.8, 図 2.9 は四角の箱が文章を表し、中身の色がトピックを表しているユニグラムモデルについて述べる。図 2.7 で示されているユニグラムモデル

は文章であるすべてのボックスが同じ色の状況を示している。すなわち，全ての文書の単語は1つのトピックから生成されたと仮定するモデルである。



図 2.7: ユニグラムモデル

混合ユニグラムモデル

図 2.8 で示されている，混合ユニグラムモデルは各ボックスの色が異なっている。つまり，各文書に一つのトピックがあり，該当するトピックから文書の単語が生成されると仮定するモデルである。



図 2.8: 混合ユニグラムモデル

LDA

図 2.9 で示されている，LDA(Latent Dirichlet Allocation)[?] では，ボックスの中で色が異なっている。つまり，各文書は複数のトピックで構成されていて，各トピックの単語分布を合算した形で単語が生成されていると仮定を行うモデルである。

LDA では文書 d 中のトピック t の単語の割合 $p(t|d)$ とトピック t で単語 w が生成される確率 $p(w|t)$ を学習データとの誤差が小さくなるように学習する。



図 2.9: LDA

トピックモデルを使用した関連研究

中村ら [?] は連結された新聞記事を LDA を用いてトピック変化点を検出して分割する実験を行った．中村らが行ったトピック変化点を検出する手順を図 2.10 に示す．

1. 現在地点より前の L_0 個の形態素を処理対象範囲 B_0 とし ($L_0 > L$; L = 文章長の下限), B_0 から複数のトピック変化点候補箇所を抽出する．図 2.10(a) に該当する．
2. B_0 を各トピック変化点候補箇所 で 2 ブロックに分割し, 2 ブロック間の類似度を計算する．そして類似度が最も小さくなるトピック変化点候補箇所 D_1 とその類似度 S_1 を求める．文書ブロック間の類似度は LDA によって求められるブロックのトピック混合比ベクトルを用いて算出する．図 2.10(b) に該当する．
3. B_0 を D_1 で分割し, 現在地点に近い側のブロックを B_1 とする．図 2.10(c) に該当する．
以降は以下 4. と 5. の処理を繰り返す ($n \geq 2$).
4. ブロック B_{n-1} に対し 2. と同様の手順でトピック変化点候補箇所 D_n とその類似度 S_n を求める．図 2.10(d) に該当する．

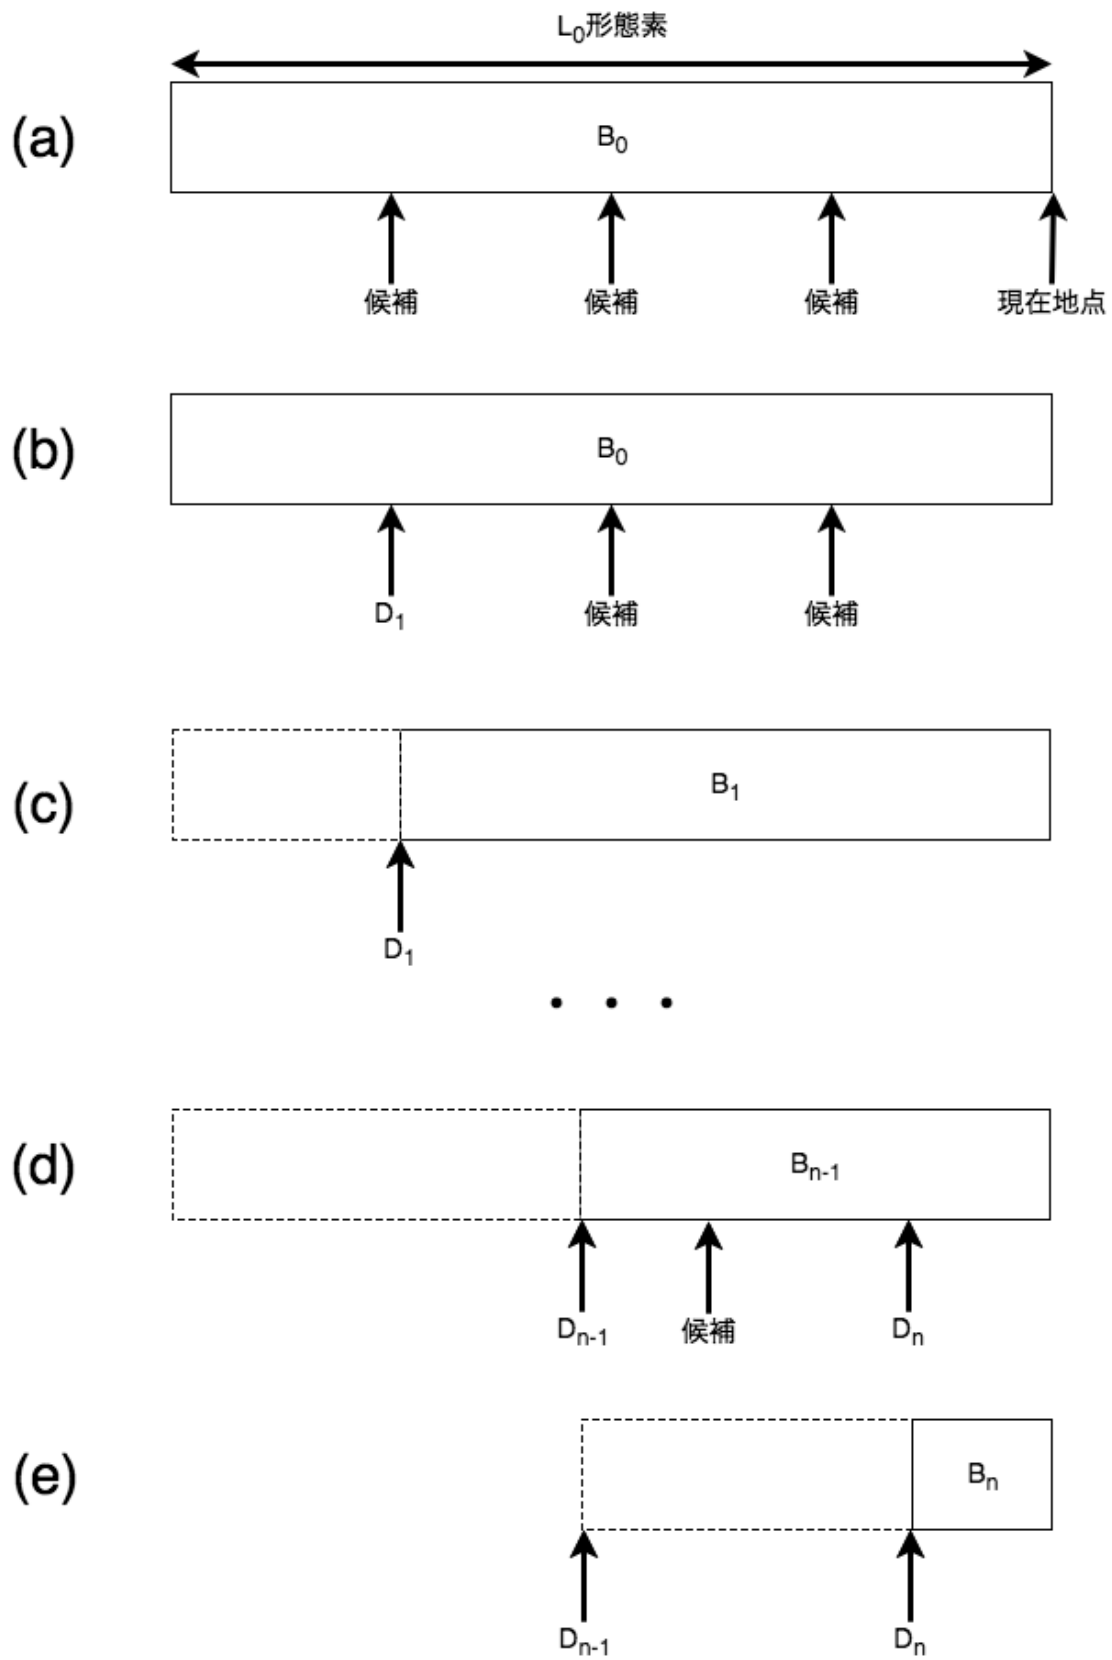


図 2.10: トピック変化点検出手順
14

5. $S_n \geq S_{n-1}$ の場合, D_{n-1} をトピック変化点として処理を終了する. $S_n < S_{n-1}$ の場合, B_{n-1} を D_n で分割し現在地点に近い側のブロックを B_n として, 処理を継続する. 図 2.10(e) に該当する.

なお, 上記 1. におけるトピック変化点候補は 1 文中でトピックが変化することは考えにくいことと計算コストを考慮し, 文境界 (句点出現位置) をトピック変化点候補としている.

以上を踏まえて, 本研究とトピックモデルを用いた研究との相違点について述べる. トピックモデルはトピックに基づいて学習を行っていて, 基本的に学習の際にトピックの数を指定する必要がある, 指定に伴いトピック数が制限されてしまう. また, 教師なし学習であるので必ずしも話題を捉えた学習がされるとは限らない. すなわち, トピックの数によっては変化に対応できない話題が存在することがあり得る. 本研究はトピックの指定が必要な LDA によるトピックモデルとは違い, トピックに関係なく単語の共起頻度を学習する fastText を用いている点で異なる. 更に, 本研究は中村らの研究とは話題の変化点を判定する際に複数候補から類似度が最小である候補点を選ぶのではなく, 候補点を逐一調べ閾値よりも下かどうかで変化点を判定している点や対象とするデータが新聞記事ではなく議論である点でも異なる.

2.5 重み付け

重み付けは情報検索を主とする分野で使われる方法で, 蓄積された情報中の語の索引語, すなわち特定の情報の特徴を表し検索の手掛かりとなる語, としての重要度を数値的に表現し, それぞれの語の重要度に応じて重みを付け, 集計して

総合評価を出す手法である。出された総合評価はスコア等と呼ばれる。一般的に語の重要度は整数または実数値で与えられる。自動的な重み付けにおいては語の出現頻度情報や出現位置を利用して数値を与える。本研究で行う重み付けは下記の2種類の重み付けを基にしている。

2.5.1 Okapi BM25

Okapi BM25[?] は出現頻度情報を用いる重み付け手法の代表の1つである。Okapi BM25 では TF(Term Frequency 単語の出現頻度)[?], IDF(Inverse Document Frequency 逆文書頻度)[?], DL(Document Length 文書長) の3つを用いて重要度の計算を行う。各用語について説明を行う。

TF

TF は単語の出現頻度を表し、文書中において出現頻度の高い単語は重要であるという考え方に基づく。ある単語 t_i の文書 D_j 中における出現頻度重み $tf_{i,j}$ は式 (2.1) のようにして求められる。

$$tf_{i,j} = \frac{n_{ij}}{\sum_k n_{kj}} \quad (2.1)$$

ここで n_{ij} は文書 d_j における単語 t_i の出現回数、 $\sum_k n_{kj}$ は文書 d_j におけるすべての単語の出現回数の和である。

DF

DF は文書頻度を表し、文書全体で単語が何回出現したかを表す。主として後述の IDF で用いられる。ある単語 t_i の文書頻度重み df_i は式 (2.2) のようにして求めら

れる.

$$df_i = |\{d : d \ni t_i\}| \quad (2.2)$$

IDF

IDF は逆文書頻度を表し, 多くの文書において出現頻度の高い単語は重要ではないという考え方に基づく. IDF は多くの文書に出現する語, すなわち一般的な語の重要度を下げ, 特定の文書にしか出現しない単語の重要度を上げる役割を果たす. ある単語 t_i の逆文書頻度重み idf_i は式 (2.3) のようにして求められる.

$$idf_i = \log \frac{|D|}{|\{d : d \ni t_i\}|} + 1 \quad (2.3)$$

ここで $|D|$ は総文書数, $|\{d : d \ni t_i\}|$ は単語 t_i を含む文書数である.

DL

DL は文書長を表し, ある単語の出現回数が同じ 2 つの文書について, 総単語数の少ない文書と多い文書では, 前者のほうがより価値があるという考え方に基づいている. ある文書 d_j の文書長重み ndl_j は式 (2.4) のようにして求められる.

$$ndl_j = \frac{dl_j}{ave(dl)} \quad (2.4)$$

ここで dl_j は文書 d_j の総単語数, $ave(dl)$ はすべての文書の平均 dl を表す.

上記の 3 つの重みを用いて Okapi BM25 は (2.5) のように単語 t_i の文書 D_j における統合重み cw_{ij} を求める.

$$cw_{ij} = \frac{tf_{i,j} \cdot idf_i \cdot (k_1 + 1)}{k_1 \cdot (1 - b + b \cdot ndl_j) + tf_{i,j}} \quad (2.5)$$

ここで定数 k_1 と b について説明する． 2つの定数はどちらもチューニングの役割を果たすもので k_1 は単語の出現頻度による影響を， b は文書の長さによる影響を調節する．

2.5.2 LexRank

Erkan ら [?] によって考案された LexRank は Google の PageRank[?] を使用した文章要約アルゴリズムで， 文の類似度を計算して次の 2つの基準に基いて文の重要度を計算する．

1. 多くの文に類似する文は重要な文である．
2. 重要な文に類似する文は重要な文である．

LexRank でいう類似度は簡単にいえば 2文がどれだけ共通の単語を持つかということを表し， 文を TF-IDF を用いてベクトル化して Cosine を求めることで類似度としており， 式 2.6 に沿ってベクトル x と y の Cosine が計算される．

$$\text{idf-modified-cosine}(x, y) = \frac{\sum_{w \in x, y} tf_{w,x} tf_{w,y} (idf_w)^2}{\sqrt{\sum_{x_i \in x} (tf_{x_i,x} idf_{x_i})^2} \times \sqrt{\sum_{y_i \in y} (tf_{y_i,y} idf_{y_i})^2}} \quad (2.6)$$

文の間の Cosine 類似度をグラフとして可視化すると図 2.11 のようになる． 各エッジは文の間の Cosine 類似度を表し， $dXsY$ は文書 X の Y 番目の文を示す．

その後， Cosine 類似度が閾値を超えたかどうかを基に隣接行列が作成される． 隣接行列はグラフを表現するために用いられる行列で， あるノード v と w の間にエッジの有無が行列の (v, w) 成分に割り当てられる． 隣接行列の各要素を類似している文の数で割り， 確率行列に変換した後， **Algorithm1** に従って行列の固有ベク

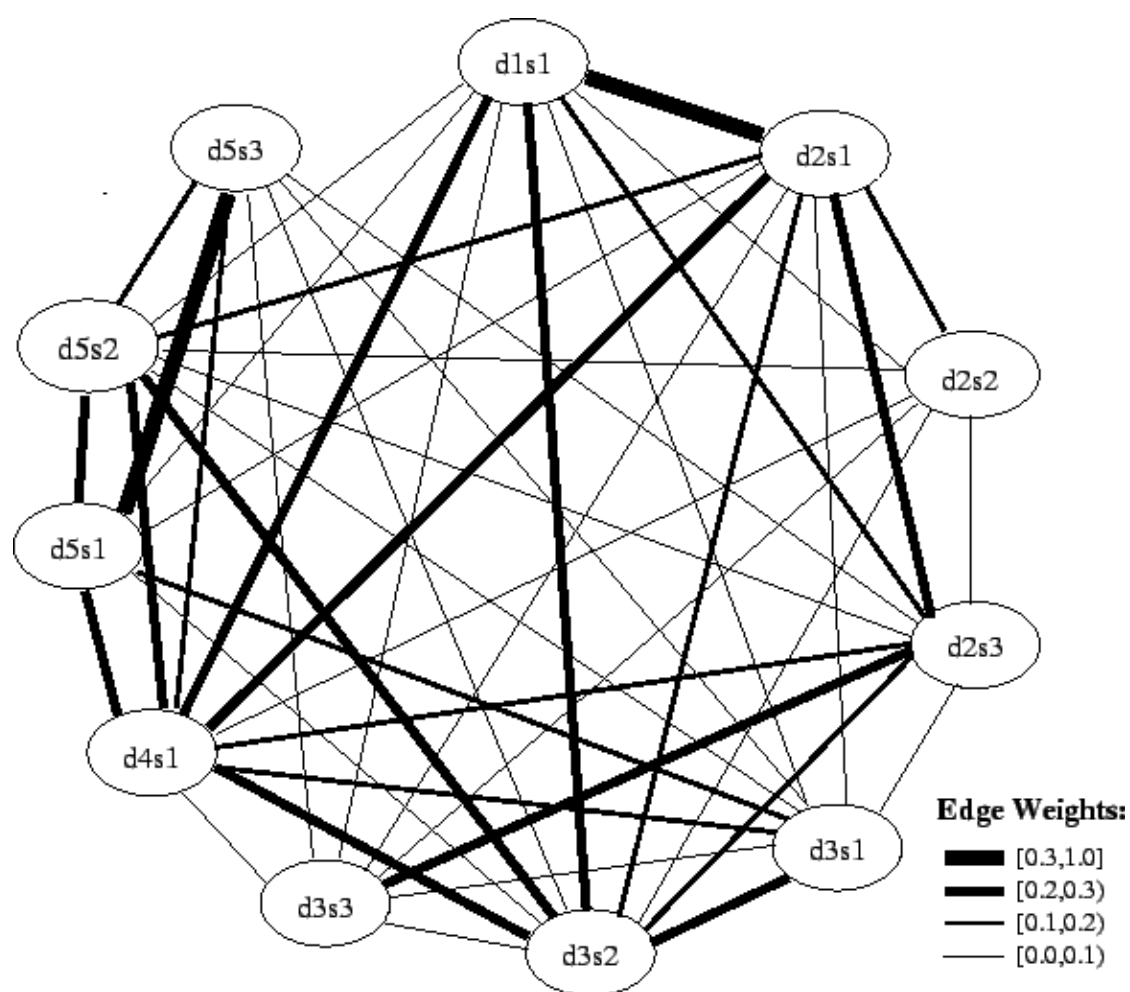


図 2.11: 類似度グラフの例

トル \mathbf{p} が計算される。求められた固有ベクトルが LexRank スコアとなる。

Algorithm 1 べき乗法の計算アルゴリズム

```
1: Input : 確率的かつ既約かつ非周期的な行列  $M$ 
2: Input : 行列サイズ  $N$ , 誤差許容値  $\epsilon$ 
3: Output: 固有ベクトル  $\mathbf{p}$ 
4: procedure POWERMETHOD( $M, N, \epsilon$ )
5:    $\mathbf{p}_0 = \frac{1}{N}\mathbf{1}$ ;
6:    $t = 0$ ;
7:   repeat
8:      $t = t + 1$ ;
9:      $\mathbf{p}_t = M^T \mathbf{p}_{t-1}$ ;
10:     $\delta = \|\mathbf{p}_t - \mathbf{p}_{t-1}\|$ ;
11:  until  $\delta < \epsilon$ 
12:  return  $\mathbf{p}_t$ ;
```

LexRank スコアを計算する一連のアルゴリズムを **Algorithm2** に示す。

7~14 行目では隣接行列が作成されており, 15~18 行目では LexRank が計算されている。

2.6 分散表現

自然言語処理では単語を低次元または高次元の実数ベクトルで表現する技術で Harris[?] 及び Firth[?] が提唱した”分布仮説”(”同じ文脈で出現する単語は類似した意味を持つ傾向があり, 単語はその単語とともに出現する単語等によって特徴づけられる。”という考え方)に基づいている。

2.6.1 単語文脈行列

単語文脈行列は分散表現の最も基本的な形式で図 2.12 のような形の行列で表される。

Algorithm 2 LexRank スコアの計算アルゴリズム

```
1: Input :  $n$  個の文からなる配列  $S$ , コサイン類似度の閾値  $threshold$ 
2: Output : 各文の LexRank スコアを格納した配列  $L$ 
3: Array  $CosineMatrix[n][n]$ ;
4: Array  $Degree[n]$ ;
5: Array  $L[n]$ ;
6: procedure LEXRANK( $S, t$ )
7:   for  $i \leftarrow 1$  to  $n$  do
8:     for  $j \leftarrow 1$  to  $n$  do
9:        $CosineMatrix[i][j] = \text{idf-modified-cosine}(S[i], S[j])$ ;
10:      if  $CosineMatrix[i][j] > threshold$  then
11:         $CosineMatrix[i][j] = 1$ ;
12:         $Degree[i] ++$ ;
13:      else
14:         $CosineMatrix[i][j] = 0$ ;
15:   for  $i \leftarrow 1$  to  $n$  do
16:     for  $j \leftarrow 1$  to  $n$  do
17:        $CosineMatrix[i][j] = CosineMatrix[i][j] / Degree[i]$ ;
18:    $L = \text{PowerMethod}(CosineMatrix, n, \epsilon)$ ;
19:   return  $L$ 
```

コーパス中の単語		単語の前後に出現する単語						
		have	new	drink	bottle	ride	speed	read
	beer	36	14	72	57	3	0	1
	wine	108	14	92	86	0	1	2
	car	578	284	3	2	37	44	3
	train	291	94	3	0	72	43	2
	book	841	201	0	0	2	1	338

図 2.12: 単語文脈行列

(<https://www.slideshare.net/naoakiokazaki/20150530-jsai2015> の表を筆者修正)

行列中の各要素 M_{ij} は単語 i と文脈 j の共起頻度を表しており、例として青い四角は train と ride が 72 回共起したことを表している。各行 M_i は単語 i の意味ベクトルを表し、例として赤い四角は”beer”の単語ベクトルを表している。また、単語の類似度を式 2.7 のように単語の意味ベクトルのコサイン類似度で求めることができる。

$$\cos\theta = \frac{M_i \cdot M_j}{|M_i||M_j|} \quad (2.7)$$

式 2.7 を図 2.12 の行列に適応させると beer と wine のコサイン類似度は約 0.941, beer と train のコサイン類似度は約 0.387 となり, train よりも wine の方が beer に類似していることが分かる。

2.6.2 word2vec

2.6.1 節で説明した単語文脈行列から得られる単語ベクトルは単語の類似度を求めることは出来たが，他の数学的処理には対応していなかった．Mikolov ら [?] が開発した word2vec はニューラルネットワークを用いて分散表現の生成を行う手法で，文脈または単語を予測するようにニューラルネットワークで学習を行い，隠れ層をベクトルとする．具体的には word2vec で使用される学習方法には CBOW と skip-gram の 2 種類が存在する．図 2.13，図 2.14 はそれぞれ CBOW と skip-gram の構造を表す．




図 2.13: CBOW




図 2.14: skip-gram

CBOW は周辺の単語 $W(t-2) \cdots W(t+2)$ を入力として，現在の単語 $W(t)$ を予測することを目指して学習する．逆に skip-gram は現在の単語を入力として，周辺の単語を予測することを目指して学習する．どちらの手法でも中間層と単語の

変換処理が行われており，学習によって得られる単語と中間層での数値が対応した行列が単語の分散表現モデルとなる．

word2vec が従来の手法と比べて大きく異なる点は ニューラルネットによる学習で単語類似度の計算に加えて，ベクトルの加減算が単語の意味の加減算に対応しているということである．加減算に対応できる意味を学習していることから異なる言語においても類似した単語の関係性が学習でき，機械翻訳において高い性能を示すことが Mikolov ら [?] が示している．また，従来の手法を用いた単語ベクトルよりも類推精度が高いことが Levy ら [?] によって示されている．例えば， $X = \text{vector}(\text{"biggest"}) - \text{vector}(\text{"big"}) + \text{vector}(\text{"small"})$ として計算されたベクトル X に最も類似したベクトルを探すことで biggest が big に類似しているのと同じ意味で small に類似している単語 smallest を見つけることができる．ただし，分散表現モデルが十分に訓練されていることが前提である．

2.6.3 fastText

fastText[?][?] は word2vec を発展させた手法でより大きな語彙や多くの稀な単語に対応することができ，学習の速度を上昇させることに成功している．

fastText は skip-gram モデルを採用しており，学習の際に単語だけでなく部分語(単語を構成する文字のまとまり)についても考慮する．以下に単語 w_t が与えられた時に予測した文脈単語 w_c の間のスコア関数を示す．

$$s(w_t, w_c) = \mathbf{u}_{w_t}^T \mathbf{v}_{w_c} \quad (2.8)$$

$$s(w_t, w_c) = \sum_{g \in \mathcal{G}_w} z_g^T v_{w_c} \quad (2.9)$$

式 2.8 は fastText 以前の手法でのスコア関数を表し，式 2.9 は fastText でのスコア関数を表す． \mathbf{u}_{w_t} ， \mathbf{v}_{w_c} はそれぞれ単語 w_t ， w_c を実数ベクトルで表したもので，式 2.9 において \mathcal{G}_w ， z_g はそれぞれ単語 w の n-gram の集合と n-gram g を実数ベクトルで表現したものを表す．式 2.8 では単語と文脈単語の間のスカラー積をスコアとしているが，式 2.9 では単語の n-gram と文脈単語の間のスカラー積の合計をスコアとしている．式 2.9 の手法を用いることで従来のモデルでは考慮されていなかった”活用形”を考慮できるようになった．例として，単語 go と goes と going は全て go の活用形であるが字面は異なるので従来のモデルでは異なる単語として学習されていたが，fastText では部分語である”go”を 3 つ全てで学習することで意味の近い単語として学習することが可能となることが挙げられる．

本研究では分散表現の手法として fastText を使用している．

2.6.4 分散表現を使用した話題関連研究

分散表現は関連語を導出できることから分散表現を話題関連に用いる研究が行われている．中野ら [?] は分散表現を用いて雑談対話システムでのシステム側の応答生成を行っている．図 2.15 に話題展開システムの構造を示す．

システムではユーザ発話を形態素解析して検出された単語を単語分散表現による類似語検索から得られた結果と入れ替えることでシステム応答の生成を行っている．

また，Li ら [?] は分散表現を用いて Twitter のツイートをトピックカテゴリに分

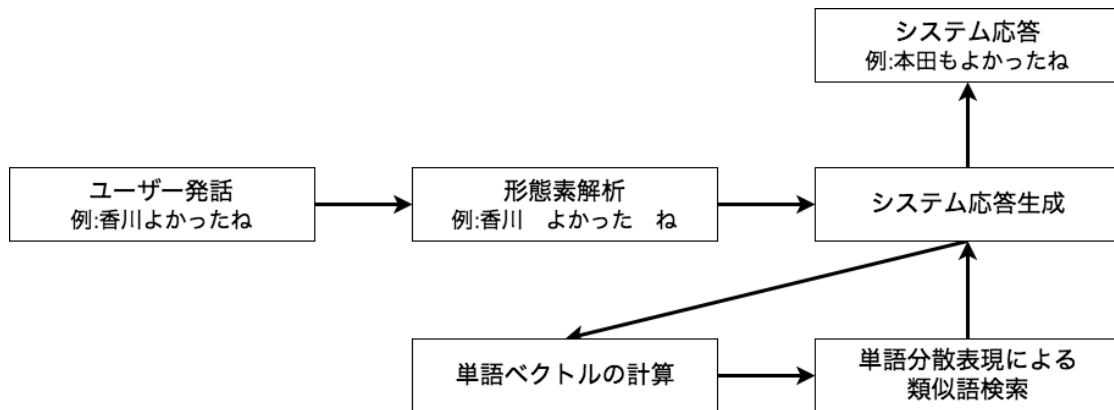


図 2.15: 話題展開システムの構造

類する分類器 TweetSift を提案している。図 2.15 にトピックカテゴリーの予測のワークフローを示す。

図 2.15 の右のフローではツイートデータとスクレイピングで作成された知識ベースを用いて知識ベース特徴を生成している。図 2.15 の左のフローでは前処理を行ったツイートと作成済み分散表現モデルを用いて分散表現特徴を生成している。2 つの特徴を用いて SMO(Sequential Minimal Optimization)[?] によってトピックが予測されている。Li らの研究で用いられる分散表現は学習の際に単語だけでなく、LDA を用いて予測した単語のトピックも使用されている。

以上を踏まえて、本研究と分散表現を用いた研究との相違点について述べる。本研究は Web 上での議論を対象としており、対話や SNS を対象としていない点で異なる。また、中野らの研究とは文の生成を行わない点でも異なり、Li らの研究とは分散表現の学習の際にトピックを用いていない点でも異なる。

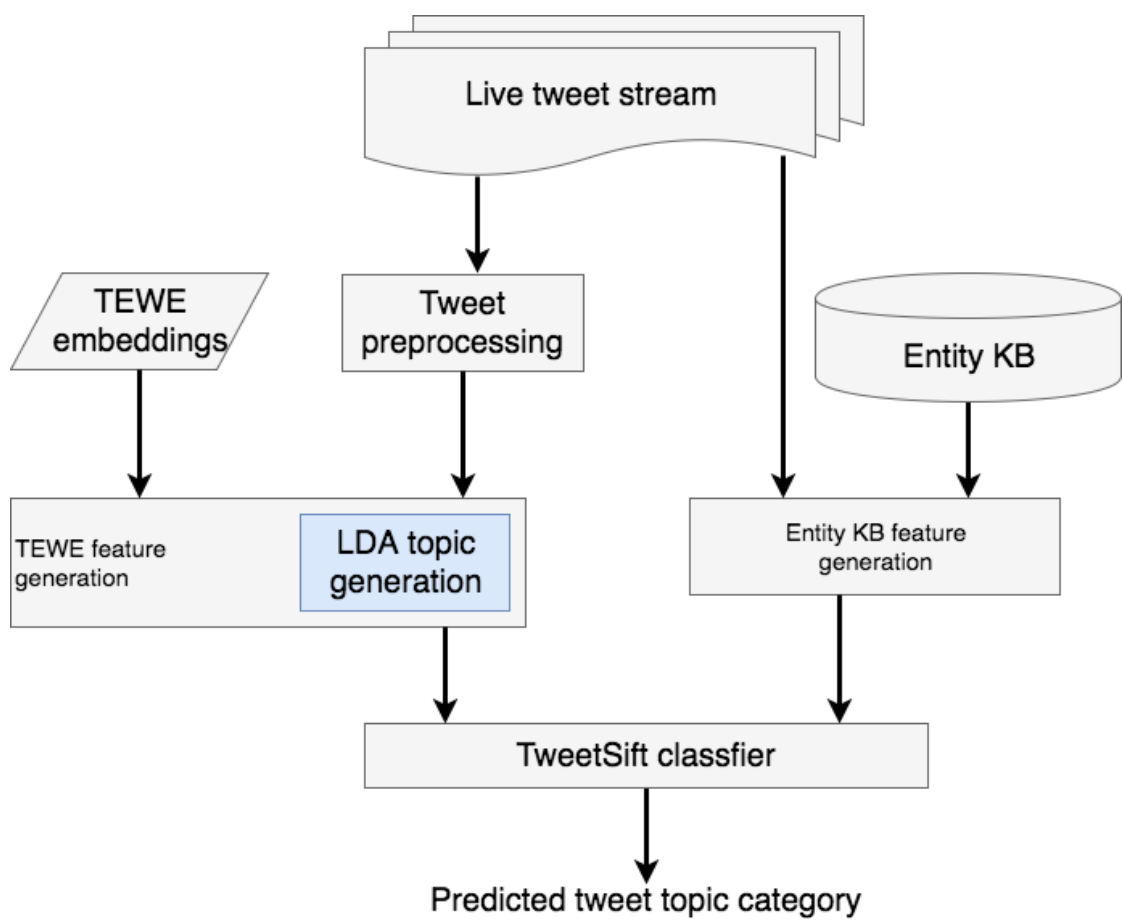


図 2.16: TweetSift によるトピック予測のワークフロー

2.7 結言

本章では，COLLAGREE の開発の背景及び概要と COLLAGREE 上で既存の議論支援について説明し，本研究で支援することを目的とするファシリテーターについても説明した．次に，既存の議論支援研究を紹介して本研究との相違点を説明した．また，話題に関連する研究の概要と話題遷移を研究している点で本研究と関連している研究についても述べ，本研究との相違点を説明した．そして，本研究での重要な要素である重み付けと分散表現についてと，分散表現を使用した関連研究について説明し，本研究との相違点を説明した．